

# 刘文豪

AI算法工程师（具身智能/多模态/视觉感知）

13767001968 | liuwenhao1968@163.com

GitHub: <https://github.com/nanxiang11>



Research Focus: 具身智能 | 大模型多模态 | 视觉感知

## 教育背景

上海工程技术大学-电子信息硕士

2023-09~2026-06

研究方向: 具身智能、大模型、多模态、轻量化语义分割、多尺度特征建模、工业视觉感知

### 获取与荣誉:

国家级: 21届研究生数学建模国二(队长)、CAAI智新杯国二、23届机器人与人工智能国三、研究生国家奖学金;

省级: 江西省工程训练省二(队长)、机器人大赛省三、上海市双创市级立项;

校级: 研究生学业奖学金(排名第一)、数学建模校二、互联网+校三、程创杯校三、三好学生、机械创新校一等。

## 科研与算法创新成果

### V<sup>2</sup>Net: A Nested Framework for Crack Segmentation Based on Multiscale Feature Learning

(第一作者) *IEEE Transactions on Instrumentation and Measurement* (Q1 if=5.9)

- 针对工业裂缝分割中目标尺度变化剧烈、细粒度结构易在多次下采样中丢失的问题,从特征组织结构层面分析了 UNet / UNet++在多尺度建模上的冗余融合与语义错位问题;
- 提出一种嵌套式多尺度特征学习框架(V<sup>2</sup>Net),将网络拆解为多个VNet子结构,并通过匹配式跳跃连接实现跨尺度单元的语义对齐与特征复用,在保持计算效率的同时增强结构表达能力;
- 设计面向裂缝方向性与细粒度几何特征的渐进式特征增强机制,有效缓解多尺度特征融合过程中关键信息衰减的问题;
- 在多个裂缝数据集上显著优于 UNet、UNet++ 等主流方法,在目前最大的裂缝分割数据集KHANHHA数据集,相较Unet基线模型提升41.69%IoU,相较最新模型CrackSAM, CSBSR分别提升1.56%与1.21%IoU,达到SOTA 66.51%的IoU。

### HAFNet: Hierarchical Attention and Feature Fusion for Real-Time Lightweight Semantic Segmentation

(第一作者) *IEEE TPAMI* (Under Review) (Q1 if=18.6)

- 从语义分割网络的层级功能划分出发,系统分析了浅层、中层与深层特征在边界建模、结构感知与语义抽象中的不同作用,指出传统轻量化模型在多尺度特征协同建模上的不足;
- 提出一种分层协同的轻量化语义分割架构(HAFNet),通过明确的功能划分与模块协作,实现不同层级特征的针对性建模:
  - 在浅层设计 AcquisitionFeature 模块,强化边缘、纹理等低级特征的有效提取并抑制冗余信息;
  - 在中层设计 MS-ACSBlock,融合多尺度建模与注意力机制,提升对局部结构与目标轮廓的感知能力;
  - 在深层设计 GeoLiteConv 模块,增强语义抽象与全局上下文建模能力,在保持轻量化的同时提升类别判别性;
- 基于上述分层协同设计,构建了具有清晰层级结构与功能分工的 HAFNet 网络,在 Crack500、MIAD (WindFarm)、WHDL D及 Cityscapes 等多个复杂场景数据集上进行了系统评测;
- 实验结果表明, HAFNet 在遥感航拍场景 (WHDL D) 中取得 63.17% MIoU,显著优于多种主流基线模型,特别以计算量 1.98GFLOPs与参数量1.19M极其轻量的模型表现分别超过RSAM-Seg、RS-SAM和MGNet等一众视觉大模型2.97%、2.47%和1.2%MIoU。在可视化图中出现预测图像超过人工专家标注的强大泛化能力。

### 具身智能无人零售系统（VLA + 多模态决策）（探索阶段）

- **背景：**面向24h无人零售超市场景，构建具备环境感知与指令理解能力的具身智能系统，解决复杂货架结构下目标定位困难、任务决策不稳定等问题。
- **核心工作：**
  - 基于  $\pi 0.5$  模型进行场景微调适配，针对零售场景构建指令-动作数据，对模型进行任务适配，实现从自然语言指令到动作序列的决策生成。
  - 通过遥操作数据采集流程，同步采集图像、指令与动作序列数据，构建标准化训练样本，数据一致性采集，动作规范化控制采集。
  - 主导视觉检测结果与 Prompt 融合策略设计：将商品类别、空间位置等检测信息结构化语言提示，引导模型关注关键区域，缓解纯VLA在细粒度目标定位与复杂场景理解中的不稳定问题。
  - 参与部分系统联调，对接导航模块（slam），将模型输出的动作序列映射为实际控制指令，验证任务在真实环境中的执行效果。对模型输出进行分析与优化，结合任务失败案例对数据分布与指令表达进行调整。
- **成果：**  
完成系统初步方案实现，并实现关键流程的端到端打通

### 图像质量分类模型与半自动化数据生成引擎（落地可迁移）

- **背景：**租户上传图片质量参差不齐，底库千万级数据中低质量图像比例高，传统方法难覆盖复杂场景，影响下游模型精度。
- **创新策略与方法：**
  - 设计半自动化数据生成闭环，将传统模拟方法（高斯噪声、运动模糊、压缩、亮度变化）与风格迁移生成结合，实现训练数据多样化。
  - 优化EfficientNetV2模型，配套多卡训练框架，实现百万级图像训练，千万级图像推理可行性。
  - 构建数据迭代优化闭环：模型推理筛选 → 人工校验 → 再训练，循环优化训练集与数据策略尽可能覆盖更多长尾，提升模型在复杂场景下的性能。
- **成果：**生成 100w+ 高质量训练图像，测试集准确率达 99.7%，清理历史遗留脏数据100w+，及时补充优质图像数据，提升图像检索模型的成功率。

### 人体图像分割数据集生成引擎（智能冰箱场景）（落地可迁移）

- **背景：**智能冰箱售货场景，因人体遮挡商品严重、光照复杂、衣物/背景相似度高，导致商品识别失败。希望获取遮挡程度。
- **创新策略与方法：**
  - 构建分割数据生成闭环：人工标注 → SegFormer 初训练 → SAM 提示批量生成高质量 Mask → 自动化质量分类迭代优化→人工筛选过滤。
  - 引入关键帧提取策略，通过连续帧重合投票机制确定人体关键拿去放回操作，提高分割稳定性。
  - 优化业务逻辑：将原来结算判定从“目标检测手部进入冰箱区域”替换为“人体分割mask 进入区域”，适应遮挡场景有效减少由于商品遮挡，识别不到手部。
- **成果：**有效减少人工标注成本，提升人体分割与商品结算准确率，形成可复用数据集生成方案，支持复杂零售场景快速验证模型。

### 商品货架旋转检测优化（双解决方案）（落地）

- **背景：**针对零售场景中商户商品摆放检测需求，传统 YOLO 系列在旋转检测中存在长条检测框拟合不全、目标密集长条货架检测框重叠严重的问题。
- **策略与方法（plan A）：**
  - 替换训练损失函数（引入 GIoU）提升旋转框拟合精度。
  - 引入复杂场景样本增强，改进数据裁剪策略，保证推理与训练一致性，加大效果不佳场景的数据量。
  - 更改原始数据加载器代码，调整数据读取流程与图像缩放策略将标注的短边在数据预处理环节变的更短一些，有效减少末端检测框重叠。
  - **成果：**该方案相较原来提升6.5%的检测准确率和3.1%召回率。（线上实际使用）
- **策略与方法（plan B）：**
  - 使用yolo分割模型解决当前场景问题，可以显著提升层架区域拟合能力，并且没有旋转检测的一系列问题。但同时分割模型会带来计算量的提升和后处理工作的加剧。
  - 可以通过对分割区域做预处理取内接四边形作为模型输出来兼容旋转检测模型的格式输出，避免下游逻辑环节的更改。
  - **成果：**线下测试完美拟合所有层架！

### 具身智能多模态情感交互系统研发（LLM + TTS）

- **背景**：面向具身智能机器人场景，构建具备情感理解与表达能力的人机交互系统，解决传统语音对话系统“无情绪 / 表达单一”的问题。
- **核心工作与方法**：
  - 基于Qwen3模型微调，构建具备情感感知能力的对话模型，实现语义与情绪的联合建模。设计情感提示词体系（Prompt Engineering），将文本语义映射为结构化情感信息（情绪类别8个向量维度嵌入）。
  - 设计LLM 情绪向量 TTS控制链路，利用8维情绪向量实现连续情感建模与语音风格可控生成。
  - 构建完整推理流程：LLM生成 ->情感解析->情绪向量映射 TTS合成，实现实时交互闭环。
- **成果与效果**：
  - 实现多情绪（高兴 / 悲伤 / 平静等）语音表达能力提升语音交互自然度。
  - 支持情绪强度调节与混合表达（连续情感空间），增强表达细腻度。
  - 构建标准化情感控制接口，实现 LLM 与 TTS 的模块解耦与快速集成。
  - 完成从模型微调、推理链路设计到系统部署的全流程工程落地。

### 星语系列 | 大模型与多模态系统快速实践（个人项目 用时一周左右）

#### 星语--MoE：自研MoE架构大模型(0.2B参数量 CPU运行 10token/s)

- **项目链接**：[https://github.com/nanxiang11/CodeLab\\_LLM](https://github.com/nanxiang11/CodeLab_LLM)（未来百星项目，当前76star+）
- **在线体验地址**：<https://www.modelscope.cn/studios/nanxiang1968/XY-MoE>
- **项目目标**：在无既有大模型工程经验情况下，快速理解 Transformer 架构，MOE原理，完成可训练推理的最小闭环实现。
- **核心实践**：
  - 从零实现 LLaMA3 核心模块（Attention、FFN、RMSNorm、Rotary Embedding），搭建轻量化训练与推理框架。
  - 设计 MoE-FFN 替换策略，使 0.2B 参数模型在 CPU 环境可推理（10 token/s），验证模块可行性。
  - 支持预训练、SFT 与 LoRA 微调流程，实现完整训练与推理闭环。
- **能力体现**：
  - 全流程动手实践：模型结构实现、训练调试、推理验证独立完成。
  - 快速迭代：1 周完成文献理解、代码实现和实验验证。

#### 星语--Vision：自研 星语 多模态大模型( 0.2B 参数量 CPU运行 6token/s)

- **在线体验地址**：<https://www.modelscope.cn/studios/nanxiang1968/XY-Vision/summary>
- **项目目标**：在无既有多模态模型工程经验情况下构建最小可验证的多模态系统，验证图像-文本联合推理能力。
- **核心实践**：
  - 基于 CLIP 视觉编码器，实现视觉 token 替换策略，将图像信息融入文本 Transformer 模型。
  - 完成端到端图像-文本推理验证，实现多模态最小闭环系统。
  - 支持预训练、SFT 与 LoRA 微调流程，实现完整训练与推理闭环。
- **能力体现**：
  - 星语系列项目旨在体现快速掌握大模型与多模态系统核心原理，并独立完成从模型实现到实验验证的全流程动手能力。
  - 我对自己的快速学习和动手能力有充分信心，这种能力同样可迁移到其他研究方向。

#### 星语--pi0：VLA 模型源码拆解与最小复现（陆续开源中）

- **项目链接**：[https://github.com/nanxiang11/XY\\_Pi0](https://github.com/nanxiang11/XY_Pi0)
- **项目目标**：基于pi0源码，构建最小可运行 VLA 系统，验证对视觉-语言-动作建模的理解，详尽分析每一个组件。
- **核心实践**：
  - 系统拆解视觉编码、语言建模与动作预测模块，梳理多模态 token 组织与特征流动。
  - 手动复现 attention、位置编码及多模态融合等关键组件，搭建最小推理闭环。
  - 跟踪 forward / loss / 推理流程，验证源码逻辑并实现从理解到实现的过渡。
- **能力体现**：
  - 能从“调用模型”深入到“实现模型”，独立完成关键模块复现，具备从 0 到 1 的工程落地能力。
  - 对数据在模型中的流动过程（输入 表征 融合 输出）具有细粒度认知，可快速迁移至其他 VLA / 多模态架构。

### Kaggle比赛项目

#### 树叶图像分类比赛（176 类，18k+ 训练样本）

- 基于 ResNet50 引入 Deformable Convolution 与轻量化 ECA注意力优化叶片细粒度特征表达，结合 Label Smoothing、Focal Loss 及 AdamW + CosineAnnealing策略训练，最终在比赛中取得前 10% 名次，分类精度 98.27%。

#### 细胞核分割 | 2018 Data Science Bowl

- 改进 U-Net 引入 Deformable Convolution 和密集跳跃连接，结合复合损失与强数据增强，实现核形态和尺度建模，比赛 IoU 57.21%，排名前 5%。